Detección de fauna silvestre en cámaras trampa con YOLOv8: desbalance, generalización a cámaras nuevas y monitoreo ecológico

Grupo 4
Martín Alexis Valdiviezo Palma Gabriel Ángel Nizama Duque
Juan José Pino Reyes César Luis Jiménez Miranda
Maestría en Inteligencia Artificial, FIIS – Universidad Nacional de Ingeniería

Resumen

Las cámaras trampa generan más imágenes de las que un equipo humano puede revisar, y la mayoría están vacías. Entrenamos un detector YOLOv8 sobre el benchmark Caltech Camera Traps (CCT-20) para localizar y clasificar 15 clases. Con la partición oficial que separa ubicaciones de cámara vistas (*cis*) de ubicaciones nunca vistas (*trans*), el mAP@0.5 cae de 0.720 a 0.455 (26.5 puntos), el desempeño por cámara nueva varía entre 0.16 y 0.74, y las especies raras pasan de 0.50 a 0.15. Al borrar al animal por *inpainting*, la misma especie se sigue detectando en el 16 % de las imágenes de cámaras vistas frente al 9 % de las nuevas, indicio de que parte del desempeño en cámaras conocidas proviene del contexto de la escena. Los animales pequeños son el caso más difícil (recall 0.45 en cámaras nuevas). Un módulo de monitoreo basado en reglas, aplicado a una cámara no vista con 6 276 fotos, estima el total de eventos independientes con un error del 6 %, pero ese acierto agregado oculta errores grandes por especie: inventa una clase ausente, omite dos especies reales y sobreestima el porcentaje de fotos vacías.

1 Motivación

Las cámaras trampa, activadas por movimiento, son hoy la herramienta estándar para inventariar mamíferos medianos y grandes en áreas protegidas, incluidos programas en la Amazonía y los Andes peruanos. Su cuello de botella es la revisión: un solo proyecto produce cientos de miles de fotos y, en CCT, alrededor del 70 % son disparos falsos por viento, vegetación o cambios de luz. Automatizar la revisión tiene dos usos distintos: (i) *filtrar* fotos vacías para ahorrar tiempo de especialista, y (ii) *identificar y contar* especies para alimentar indicadores ecológicos. El reto técnico no es solo detectar objetos: las especies siguen una distribución de cola larga, los animales aparecen pequeños, lejanos, de noche o tapados por vegetación, y, sobre todo, cada cámara está fija y ve siempre el mismo fondo, lo que invita al modelo a aprender atajos [Geirhos et al., 2020] que colapsan al instalarlo en un sitio nuevo [Beery et al., 2018].

Contribuciones. (1) Un pipeline reproducible de un solo comando que convierte CCT-20 a YOLO con manejo explícito de fotos vacías y de animales sin caja. (2) Un análisis por especie del efecto del desbalance (503:1) y de su interacción con el cambio de cámara. (3) Una medición de la brecha cis/trans complementada con dos pruebas de dependencia del fondo (energía Grad-CAM dentro de la caja y enmascarado del animal). (4) Un análisis por tamaño y oclusión. (5) Un módulo de monitoreo ecológico cuyos indicadores se validan contra la verdad de campo.

Preprint.

2 Trabajos relacionados

Clasificación de cámaras trampa. Norouzzadeh et al. [2018] mostraron, sobre Snapshot Serengeti, que una CNN puede identificar, contar y describir animales con exactitud cercana a la de voluntarios, y Tabak et al. [2019] extendieron el enfoque a especies norteamericanas. Ambos trabajos clasifican la imagen completa, sin localizar al animal. **Detección.** Schneider et al. [2018] compararon Faster R-CNN y YOLO en datos de cámaras trampa y encontraron que la detección mejora el conteo y la localización. MegaDetector [Beery et al., 2019] popularizó un detector genérico *animal/persona/vehículo* seguido de un clasificador de especie; nuestro enfoque es de una sola etapa con clases de especie, siguiendo la familia YOLO [Redmon et al., 2016, Jocher et al., 2023, Wang et al., 2024]. **Generalización geográfica.** Beery et al. [2018] introdujeron CCT-20 y sus particiones *cis/trans* precisamente para cuantificar la caída de desempeño en cámaras no vistas, y WILDS [Koh et al., 2021] incluye iWildCam como caso canónico de desplazamiento de distribución. **Desbalance.** Para detección de cola larga, Gupta et al. [2019] proponen *Repeat Factor Sampling* (RFS); la pérdida focal [Lin et al., 2017] aborda el desbalance fondo/objeto dentro de cada imagen. **Interpretabilidad.** Usamos Grad-CAM [Selvaraju et al., 2017] sobre el backbone del detector. **Ecología.** Los índices de abundancia relativa con criterio de independencia de 30 minutos siguen la práctica de O'Brien et al. [2003].

3 Datos

Caltech Camera Traps completo contiene 243 100 imágenes de 140 cámaras (105 GB). Trabajamos con su subconjunto de referencia CCT-20 (LILA BC, $\sim$6 GB), publicado por los mismos autores para evaluar generalización entre ubicaciones, con imágenes reducidas a 1024 px de lado máximo y cajas delimitadoras. La elección responde a dos razones: (i) el conjunto completo no cabe en el disco ni en la cuota de almacenamiento del entorno de cómputo disponible (Google Colab con GPU T4), y (ii) la partición que exige el experimento de generalización está definida sobre las mismas 20 ubicaciones de CCT-20: la partición oficial `eccv_train/eccv_val` de LILA corresponde a `train+cis` (ubicaciones vistas) y `trans` (ubicaciones nuevas) del artículo original [Beery et al., 2018]. Entrenamos con `train`, seleccionamos modelo y umbral con `cis_val`, y reportamos sobre `cis_test` y `trans_test`; `trans_val` no se usa para ninguna decisión. La Tabla 1 resume la composición y la Tabla 2 la prevalencia por especie. Dos rasgos de CCT-20 condicionan el resto del trabajo. Primero, a diferencia del conjunto completo ($\sim$70 % de fotos vacías), tiene pocas fotos vacías: ninguna en `train` y alrededor del 7.5 % en las particiones de prueba. Segundo, entre el 11 % y el 15 % de las imágenes de cada partición tienen etiqueta de especie pero ninguna caja.

Tabla 1: Composición de las particiones de CCT-20.

partición	imágenes	ubicaciones	% vacías	con caja	animal sin caja	cajas
train	13553	10	0.0	12099	1454	12617
cis_val	3484	10	28.6	1665	824	1763
cis_test	15827	10	7.5	12696	1951	13264
trans_val	1725	1	3.5	1533	131	1673
trans_test	23275	9	7.6	18033	3464	18786

4 Metodología

4.1 Preparación y manejo de fotos vacías

Las anotaciones en formato COCO Camera Traps se convierten a YOLO (centro, ancho, alto normalizados), reescalando las cajas al tamaño real del archivo. Tres casos por imagen: (a) *con caja*: se entrena normalmente; (b) *vacía*: el pipeline la incluye como **imagen de fondo** con archivo de etiquetas vacío (fracción configurable, 10 % de las imágenes con animal por defecto), de modo que toda predicción sobre ella es un falso positivo; (c) *animal sin caja*: se excluye del entrenamiento de detección porque el animal no anotado se aprendería como fondo, pero se conserva para el módulo de monitoreo. Como `train` de CCT-20 no contiene fotos vacías, el caso (b) no se activó y el modelo no

Tabla 2: Número de cajas por especie y partición (razón de desbalance en train: 503:1).

especie	train	cis_val	cis_test	trans_val	trans_test	% train
opossum	2514	358	4010	425	4663	19.9
rabbit	2278	366	1559	70	722	18.1
coyote	1371	200	1182	45	1902	10.9
cat	1170	169	1528	70	1366	9.3
squirrel	1037	150	510	0	782	8.2
raccoon	1030	126	981	136	4803	8.2
dog	769	106	725	80	961	6.1
bobcat	684	92	772	793	1979	5.4
car	668	41	791	0	1113	5.3
bird	560	82	752	5	180	4.4
rodent	264	46	146	0	26	2.1
skunk	214	24	162	49	273	1.7
deer	44	2	140	0	0	0.3
badger	9	1	4	0	15	0.1
fox	5	0	2	0	1	0.0

vio ninguna foto vacía al entrenar. El fondo se aprende igualmente de forma implícita: en YOLOv8, todo punto de la grilla no asignado a una caja recibe objetivo cero en la rama de clasificación, así que el fondo de cada foto con animal actúa como ejemplo negativo. Las fotos vacías de `cis_val` se usan para fijar el umbral operativo y las de prueba para medir falsos positivos.

4.2 Modelo y entrenamiento

YOLOv8s [Jocher et al., 2023] preentrenado en COCO [Lin et al., 2014], entrada 640 px, AdamW ($\text{lr}_0 = 10^{-3}$, coseno), 30 épocas con parada temprana (paciencia 10), lote 16, semilla 42. Aumento de datos: mosaico (desactivado en las 5 últimas épocas), traslación 0.1, escala 0.5, volteo horizontal 0.5, jitter HSV con $v = 0.4$ para cubrir capturas infrarrojas nocturnas; *sin* rotación ni volteo vertical, porque las cámaras están fijas y los animales no aparecen invertidos.

4.3 Mitigación del desbalance de especies

Con RFS [Gupta et al., 2019], cada especie c con frecuencia de imagen f_c recibe $r_c = \max(1, \sqrt{t/f_c})$, $t = 0.1$; cada imagen se repite $r_i = \max_{c \in i} r_c$ veces (redondeo estocástico). Así las especies raras se ven más a menudo sin alterar la pérdida. RFS está implementado en el pipeline (experimento `rfs`), pero por el límite de cuota de GPU no alcanzamos a entrenarlo: todos los resultados corresponden al modelo base, entrenado sin remuestreo.

4.4 Evaluación

Implementamos un evaluador estilo COCO (interpolación de 101 puntos, IoU 0.50:0.05:0.95) con soporte de cajas *ignoradas*, verificado con pruebas unitarias, porque los análisis por subgrupo requieren excluir del cómputo las cajas de otros grupos. Reportamos mAP@0.5 y mAP@0.5:0.95 por especie. Además, a nivel de imagen (*¿hay fauna?*), elegimos el umbral operativo que maximiza F1 en `cis_val` y reportamos precisión, recall, F1, AUC y tasa de falsos positivos en fotos vacías.

4.5 Robustez ante oclusión y tamaño

El tamaño relativo es área de la caja / área de la imagen, con cortes en 1 % y 10 % (pequeño, mediano, grande). CCT no trae etiquetas de oclusión; definimos un proxy $s = \frac{1}{2}\mathbb{1}[\text{caja truncada por el borde}] +$

$\frac{1}{2}\,\mathrm{rank}(\rho_{\text{bordes}})$, donde ρ_{bordes} es la densidad de bordes Canny dentro de la caja (la vegetación interpuesta fragmenta la silueta), discretizado en terciles. El repositorio genera una muestra estratificada de 300 cajas de `trans_test` para validar el proxy con anotación manual (kappa ponderado); esa validación no se completó para este informe. Por subgrupo calculamos mAP y recall al umbral operativo.

4.6 ¿Animal o fondo?

Grad-CAM. Implementamos Grad-CAM con *hooks* sobre la capa 6 del backbone (C2f, paso 16); el objetivo es el score de la especie verdadera en la ancla de mayor activación. Medimos la fracción de energía del mapa dentro de la caja GT y la normalizamos por el área relativa (1 = mapa uniforme). **Enmascarado.** Borramos al animal con *inpainting* [Telea, 2004] y volvemos a detectar: si la misma especie sigue apareciendo con confianza sobre el umbral, la decisión depende del contexto y no del animal.

4.7 Módulo de monitoreo ecológico

Sobre todas las fotos de una cámara *trans*, aplicamos reglas: (R1) umbral por especie; (R2) supresión entre clases con IoU>0.7; (R3) foto con fauna si sobrevive una detección; (R4) agregación por secuencia de disparo, especie por suma de confianzas y conteo MaxN; (R5) fusión de secuencias de la misma especie separadas por menos de 30 minutos (eventos independientes); (R6) indicadores: % de fotos vacías, riqueza, eventos, RAI$=100\cdot$eventos/días-trampa y % nocturno. El mismo motor se aplica a la verdad de campo para medir cómo se propagan los errores del detector.

5 Experimentos y resultados

5.1 Desempeño por especie y efecto del desbalance

Tabla 3: AP por especie del modelo baseline en ubicaciones vistas (cis) y nuevas (trans). (*): tercio de especies con menos cajas de entrenamiento.

especie	cajas train	AP50 cis	AP50:95 cis	AP50 trans	AP50:95 trans
opossum	2514	0.914	0.509	0.877	0.459
rabbit	2278	0.896	0.559	0.677	0.350
coyote	1371	0.915	0.697	0.570	0.403
cat	1170	0.866	0.585	0.278	0.185
squirrel	1037	0.707	0.384	0.275	0.154
raccoon	1030	0.922	0.607	0.735	0.481
dog	769	0.680	0.477	0.713	0.491
bobcat	684	0.794	0.567	0.556	0.377
car	668	0.999	0.994	0.995	0.989
bird	560	0.614	0.323	0.076	0.043
rodent *	264	0.789	0.426	0.001	0.001
skunk *	214	0.945	0.631	0.500	0.323
deer *	44	0.522	0.315	–	–
badger *	9	0.000	0.000	0.116	0.079
fox *	5	0.236	0.191	0.000	0.000

El desbalance es extremo: *opossum* tiene 2 514 cajas de entrenamiento y *fox* 5 (razón 503:1), y tres cámaras concentran el 53 % de las imágenes de entrenamiento. En cámaras vistas, la frecuencia explica solo parte del desempeño: las clases con más de 1 000 cajas superan 0.70 de AP@0.5, pero *skunk* alcanza 0.945 con 214 cajas, mientras que *bird* (560) se queda en 0.614; la forma y el tamaño del animal pesan tanto como el número de ejemplos. Las cinco especies con menos cajas promedian 0.499 de AP@0.5 en cis y 0.154 en trans: el desbalance y el cambio de cámara se suman, aunque el promedio en trans descansa en muy pocas instancias (26 cajas de *rodent*, 15 de *badger* y una sola de *fox*). *badger* (9 cajas) y *fox* (5) prácticamente no se aprenden, y *deer* no tiene instancias en `trans_test`, por lo que su AP en trans no se define.

La caída cis→trans, sin embargo, no sigue a la frecuencia. *cat* (1 170 cajas) cae de 0.866 a 0.278 y *squirrel* de 0.707 a 0.275, mientras que *opossum* se mantiene (0.914→0.877) y *dog* incluso mejora

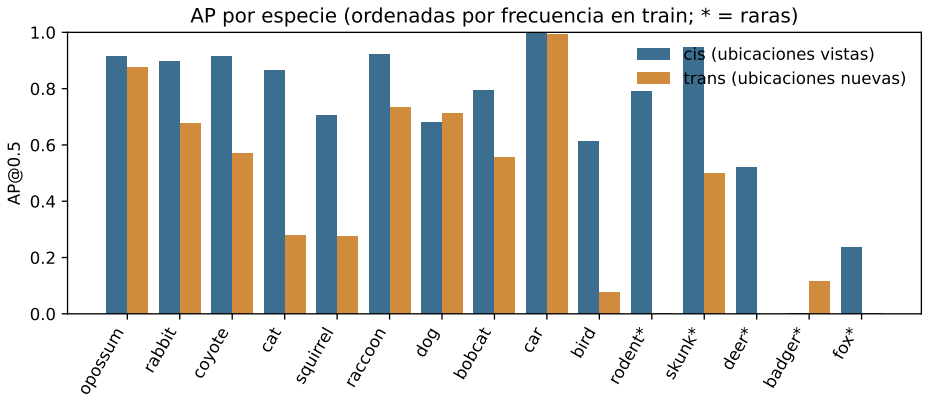


Figura 1: AP@0.5 por especie en ubicaciones vistas (cis) y nuevas (trans), ordenadas por frecuencia.

(0.680→0.713); *rodent* colapsa de 0.789 a 0.001, sobre solo 26 cajas. Nuestra hipótesis es que la generalización depende menos de cuántos ejemplos hay que de en cuántas cámaras distintas aparece la especie: una especie vista sobre pocos fondos se aprende junto con ellos. *car*, un objeto grande y rígido, es casi perfecto en ambos casos (0.999 y 0.995).

Tabla 4: Filtrado de fotos vacías a nivel de imagen con umbral 0.475 (elegido en cis_val maximizando F1).

partición	umbral	precisión	recall	F1	FP en vacías	AUC
cis_test	0.475	0.994	0.919	0.955	0.064	0.970
trans_test	0.475	0.989	0.847	0.912	0.096	0.929

Como filtro de fotos vacías, el modelo es muy preciso: al umbral 0.475, el 99 % de las fotos que marca con fauna la tienen, en cámaras vistas y nuevas (Tabla 4). Lo que se degrada es el recall, de 0.919 a 0.847: en cámaras nuevas, 15 de cada 100 fotos con animal se descartarían como vacías. La tasa de falsos positivos en fotos vacías sube de 6.4 % a 9.6 % y el AUC de 0.970 a 0.929, a pesar de que el modelo nunca vio una foto vacía al entrenar. La precisión, sin embargo, está inflada porque en estas particiones solo ∼7.5 % de las fotos están vacías; la cifra que se traslada a un despliegue real es la tasa de falsos positivos. Con 70 % de fotos vacías, como en el conjunto completo, esa tasa y el recall de trans darían una precisión cercana a 0.79.

5.2 Generalización a cámaras nuevas

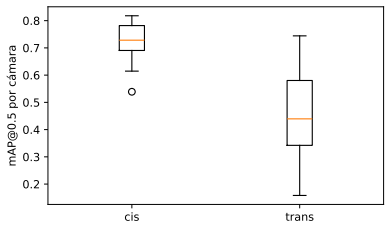


Figura 2: mAP@0.5 por cámara: dispersión entre ubicaciones vistas y nuevas.

El mAP@0.5 baja de 0.720 a 0.455 (-26.5 puntos, $-37\,\%$ relativo) y el mAP@0.5:0.95 de 0.484 a 0.310. La dispersión entre cámaras también crece: en las 10 cámaras vistas el mAP@0.5 va de 0.54 a 0.82, y en las 9 nuevas de 0.16 a 0.74 (Figura 2). En la práctica, el desempeño en un sitio nuevo es difícil de anticipar, que es justamente lo que importa al desplegar.

Tabla 5: Test de enmascarado: el animal se borra por inpainting; % persiste = la misma especie sigue detectada con score ≥ 0.47.

partición	n	score original	score sin animal	% persiste
cis_test	400	0.75	0.15	16.25
trans_test	400	0.70	0.09	9.00

Enmascarado. Es la evidencia más clara (Tabla 5). Al borrar al animal, el score de su especie cae en promedio de 0.75 a 0.15 en cámaras vistas y de 0.70 a 0.09 en nuevas: en la gran mayoría de los casos el modelo sí depende del animal. Pero en el 16.3 % de las imágenes de cámaras vistas la misma especie se sigue detectando sobre el umbral sin el animal, frente al 9.0 % en cámaras nuevas. Esa diferencia es la firma esperada de un atajo de contexto: en las cámaras de entrenamiento el fondo por sí solo sugiere la especie que suele pasar por ahí, y esa ayuda desaparece en un sitio nuevo, lo que contribuye a la brecha. Dos precauciones: solo se borra la caja más grande, de modo que en imágenes con varios individuos de la misma especie la detección puede persistir legítimamente, y el *inpainting* deja artefactos.

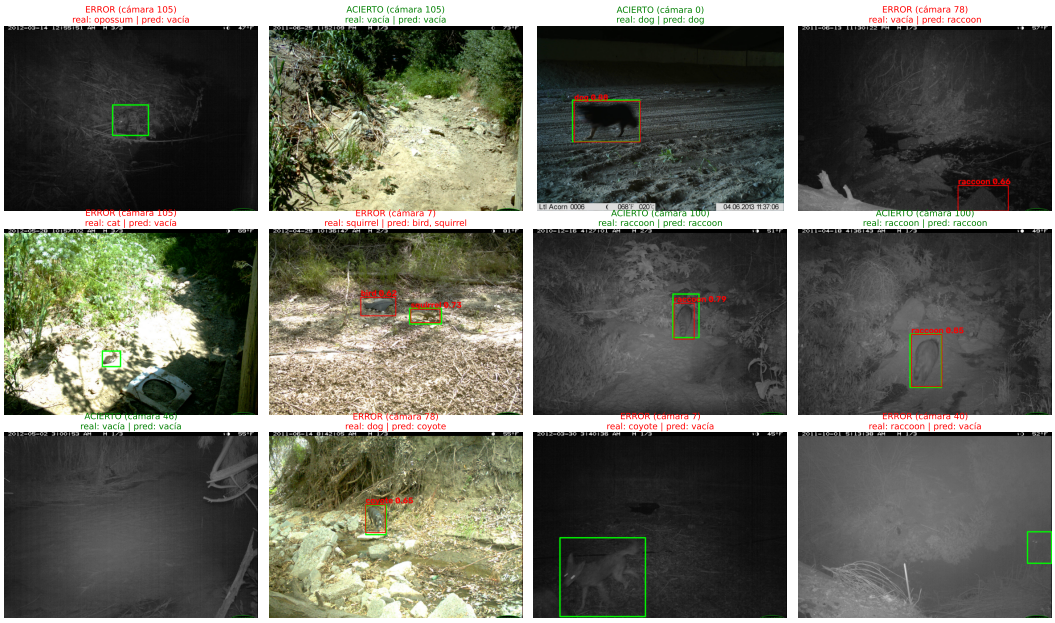


Figura 3: Detecciones en cámaras nuevas (verde = verdad de campo, rojo = predicción, umbral 0.475). Muestra aleatoria de 12 fotos; los errores típicos son omisiones de animales oscuros u ocluidos de noche y confusiones de especie con la caja bien localizada.

Tabla 6: Grad-CAM: fracción de la energía del mapa dentro de la caja GT (concentración = energía / área relativa; 1 = uniforme).

partición	acierto	n	energía en caja	área relativa	concentración
cis_test	no	61	0.098	0.065	0.973
cis_test	sí	339	0.108	0.107	0.689
trans_test	no	125	0.145	0.122	0.923
trans_test	sí	275	0.114	0.116	0.674

Grad-CAM. No resultó informativo. La fracción de energía dentro de la caja es similar a la fracción de la imagen que ocupa la caja (concentración mediana entre 0.67 y 0.97, donde 1 equivale a un mapa uniforme) en todos los grupos, y no distingue cis de trans (Tabla 6); incluso los errores muestran una concentración algo mayor que los aciertos. Interpretamos que el mapa de la capa 6 del backbone,

calculado sobre una sola ancla, es demasiado difuso para localizar la evidencia en un detector de una etapa, y no lo usamos como prueba de dependencia del fondo.

5.3 Robustez ante oclusión y tamaño

Tabla 7: Robustez por tamaño relativo de la caja y nivel de oclusión (recall al umbral operativo 0.47, IoU 0.5).

partición	factor	grupo	cajas	mAP50	mAP50:95	recall	caída mAP50
cis	tamaño	pequeño	1149	0.285	0.117	0.605	0.488
cis	tamaño	mediano	10494	0.773	0.497	0.857	0.000
cis	tamaño	grande	1621	0.489	0.373	0.856	0.284
cis	oclusión (proxy)	bajo	4421	0.641	0.390	0.836	0.026
cis	oclusión (proxy)	medio	4421	0.604	0.366	0.853	0.063
cis	oclusión (proxy)	alto	4422	0.667	0.415	0.817	0.000
trans	tamaño	pequeño	1924	0.142	0.061	0.454	0.312
trans	tamaño	mediano	14200	0.454	0.279	0.746	0.000
trans	tamaño	grande	2662	0.202	0.174	0.552	0.252
trans	oclusión (proxy)	bajo	6262	0.363	0.214	0.826	0.071
trans	oclusión (proxy)	medio	6262	0.433	0.258	0.719	0.000
trans	oclusión (proxy)	alto	6262	0.274	0.182	0.522	0.159

Tamaño. Es el factor más fuerte. Los animales pequeños (<1 % de la imagen) tienen recall 0.605 en cis y 0.454 en trans, frente a 0.857 y 0.746 de los medianos, y su mAP@0.5 cae a 0.285 y 0.142. Los grandes también muestran un mAP bajo (0.489 y 0.202), pero en cis su recall es igual al de los medianos (0.856): esa caída de AP se debe en buena parte a un artefacto de la métrica por subgrupo, porque las detecciones sin pareja cuentan como falsos positivos en todos los grupos y pesan más en un grupo con pocas cajas (1 621 grandes frente a 10 494 medianas). Por eso, para comparar grupos de distinto tamaño usamos el recall. En trans el recall de los grandes sí cae (0.552): animales muy cercanos a la cámara, a menudo cortados por el borde, son más difíciles sobre un fondo desconocido.

Oclusión (proxy). En cámaras vistas el proxy no separa niveles de desempeño (recall 0.836, 0.853 y 0.817). En cámaras nuevas el recall cae de forma monótona: 0.826 (baja), 0.719 (media) y 0.522 (alta), y el grupo de oclusión alta tiene el menor mAP@0.5 (0.274). La oclusión parece importar justamente cuando el modelo no puede apoyarse en el conocimiento del fondo. Como el proxy no está validado con anotación manual, esta conclusión es tentativa.

5.4 Demostración del módulo de monitoreo

Tabla 8: Reporte de monitoreo de la cámara 46 (no vista en entrenamiento): reglas aplicadas a las predicciones vs. a la verdad de campo.

indicador	predicho	real
fotos	6276	6276
% fotos vacías	41.4	11.6
secuencias con fauna	1592	1869
eventos independientes	1121	1062
riqueza	11	12
días-trampa	358	358
desde	2011-05-03	2011-05-03
hasta	2012-06-13	2012-06-13

Aplicamos el módulo a la cámara 46 (trans): 6 276 fotos en 358 días-trampa, entre mayo de 2011 y junio de 2012. Los totales se acercan a la verdad de campo: 1 121 eventos independientes frente a 1 062 ($+5.6\,\%$) y una riqueza de 11 especies frente a 12 (Tabla 8). La Tabla 9 muestra que esa concordancia es una compensación de errores: el modelo inventa eventos de *car* (30 frente a 0), sobreestima *cat* (82 frente a 5) y *skunk* (82 frente a 30), subestima *raccoon* (81 frente a 156) y omite por completo *rodent* (14 eventos reales) y *badger* (1). La lista de especies predicha no es la

Tabla 9: Actividad por especie en la cámara 46: eventos independientes (30 min), RAI (eventos por 100 días-trampa) y % de eventos nocturnos.

especie	eventos pred.	eventos real	RAI pred.	RAI real	% noct. pred.	% noct. real
badger	0	1	0.0	0.3	0.0	100.0
bird	14	24	3.9	6.7	14.3	0.0
bobcat	208	225	58.1	62.8	51.4	55.6
car	30	0	8.4	0.0	56.7	0.0
cat	82	5	22.9	1.4	62.2	40.0
coyote	165	129	46.1	36.0	46.1	24.8
dog	18	4	5.0	1.1	27.8	0.0
opossum	310	327	86.6	91.3	86.8	87.8
rabbit	123	142	34.4	39.7	41.5	40.1
raccoon	81	156	22.6	43.6	84.0	90.4
rodent	0	14	0.0	3.9	0.0	85.7
skunk	82	30	22.9	8.4	86.6	80.0
squirrel	8	5	2.2	1.4	0.0	20.0

Tabla 10: Reporte de actividad por periodo generado por el módulo para la cámara 46 (no vista en entrenamiento): eventos independientes por mes y especie, total y riqueza mensual.

mes	opossum	bobcat	coyote	rabbit	cat	skunk	otras	total	riqueza
2011-05	19	17	2	7	4	0	6	55	9
2011-06	66	34	19	14	18	10	16	177	11
2011-07	21	29	39	10	14	13	27	153	10
2011-08	24	8	12	4	2	2	7	59	10
2011-09	17	6	7	5	3	9	13	60	10
2011-10	2	0	0	0	0	0	0	2	1
2011-11	17	21	12	13	5	6	1	75	7
2011-12	7	17	15	16	6	18	8	87	8
2012-01	21	9	14	11	3	12	20	90	9
2012-02	15	15	15	6	5	4	19	79	10
2012-03	18	15	15	12	8	4	7	79	8
2012-04	40	21	8	13	4	1	8	95	8
2012-05	30	10	5	10	9	2	15	81	11
2012-06	13	6	2	2	1	1	4	29	9

real, aunque su tamaño casi coincida. En cambio, las especies frecuentes y bien aprendidas tienen abundancias cercanas a las reales (*opossum* 310 frente a 327, *bobcat* 208 frente a 225, *rabbit* 123 frente a 142) y conservan su patrón de actividad (*opossum*: 87 % de eventos nocturnos frente a 88 %). El indicador más sesgado es el porcentaje de fotos vacías: 41.4 % predicho frente a 11.6 % real. Una parte se explica por las imágenes con especie pero sin caja (15 % de `trans_test`), probablemente fotogramas de una secuencia etiquetada en los que el animal ya no es visible, que la verdad de campo cuenta como *con fauna*. La Tabla 10 muestra el reporte mensual que el módulo entregaría a un equipo de manejo: la actividad máxima se da en junio y julio de 2011 (177 y 153 eventos), y octubre de 2011 registra solo 2, lo que sugiere un periodo con la cámara inactiva; por eso el RAI se normaliza por días-trampa. En la práctica, los indicadores de especies frecuentes son utilizables, pero la lista de especies y la abundancia de las raras requieren revisión humana.

6 Uso responsable de IA en conservación

Asimetría de costos. Un falso positivo cuesta segundos de un especialista que descarta una detección incorrecta; un falso negativo sobre una especie amenazada puede excluirla de los indicadores con que se decide el manejo de un área (zonificación, patrullaje, presupuesto). Para una especie con pocas detecciones al año, perder dos o tres eventos cambia su índice de abundancia relativa de forma

material, y el error es invisible porque nadie revisa las fotos ya clasificadas como vacías. Por eso el umbral no debería ser único: proponemos umbrales por especie más bajos para especies prioritarias (soportados por la regla R1), una banda de confianza intermedia que se envía a revisión humana en lugar de descartarse, y auditorías periódicas de una muestra aleatoria de fotos etiquetadas como vacías para estimar la tasa real de omisión. La métrica que conviene optimizar no es el mAP global, dominado por especies comunes, sino el recall de las especies de interés con un presupuesto de revisión acotado. Nuestros resultados lo ilustran: las especies raras pasan de 0.50 a 0.15 de AP@0.5 en cámaras nuevas, y son precisamente las que más suelen importar en conservación. En la cámara de demostración, *rodent* (14 eventos reales) desaparece por completo del reporte.

Despliegue fuera de la región de entrenamiento. Nuestros propios resultados muestran que el desempeño cae al pasar a cámaras nuevas dentro de la misma región. Llevar este modelo a la Amazonía o a los Andes peruanos añade un problema de conjunto cerrado: jaguares, tapires u osos de anteojos no existen en sus clases y serán asignados con confianza a la especie más parecida o al fondo, con vegetación, iluminación y tipos de cámara muy distintos. Antes de usar sus salidas para decisiones se requiere validación local: un lote etiquetado por especialistas en las cámaras del nuevo sitio, recall por especie con intervalos de confianza, y ajuste fino con datos locales; mientras tanto el modelo debe operar solo como filtro de vacías con revisión humana de todo lo demás. Por último, las coordenadas de detecciones de especies amenazadas son información sensible (riesgo de caza furtiva) y deben protegerse en cualquier reporte o repositorio público.

7 Limitaciones

(i) El proxy de oclusión es una heurística y no se validó con anotación manual. (ii) La métrica por subgrupo atribuye las detecciones sin pareja a todos los grupos por igual, lo que penaliza el AP de los grupos con pocas cajas. (iii) El enmascarado por *inpainting* introduce artefactos y solo borra la caja más grande de cada imagen. (iv) No entrenamos el experimento con RFS por el límite de cuota de GPU, y Grad-CAM sobre el backbone resultó demasiado difuso para ser concluyente. (v) Por presupuesto de cómputo no exploramos YOLOv9 ni resoluciones mayores, que favorecerían a los animales pequeños. (vi) Las cámaras *trans* pertenecen a la misma región; la brecha medida es una cota optimista de la brecha entre regiones. (vii) Las imágenes con animal pero sin caja se excluyen del entrenamiento, lo que puede sesgar la distribución de especies. (viii) Al usar CCT-20 y no el conjunto completo, entrenamos con menos cámaras y especies, y sin fotos vacías: incorporar fotos vacías de las mismas ubicaciones desde el conjunto completo es la extensión más directa, y con más ubicaciones de entrenamiento la brecha *cis/trans* podría reducirse.

8 Conclusión

Un YOLOv8s entrenado en 10 cámaras de CCT-20 alcanza 0.720 de mAP@0.5 en esas mismas cámaras pero 0.455 en cámaras nuevas, y las especies raras pasan de 0.50 a 0.15. El test de enmascarado indica que parte del desempeño en cámaras conocidas se apoya en el contexto de la escena, y los animales pequeños y, en cámaras nuevas, los ocluidos son los casos más difíciles. En monitoreo, los totales y las especies frecuentes se estiman bien, pero la lista de especies y la abundancia de las raras no son confiables sin revisión humana, lo que favorece usar el detector como apoyo y validarlo localmente antes de desplegarlo en un sitio nuevo.

Reproducibilidad. Código: [**Pendiente:** URL del repositorio]. Todo el pipeline (descarga, preparación, entrenamiento, evaluación, figuras y tablas de este informe) se ejecuta con `bash run_all.sh`; `bash run_all.sh -smoke` verifica el pipeline en minutos con datos sintéticos.

Referencias

Sara Beery, Grant Van Horn, and Pietro Perona. Recognition in terra incognita. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 456–473, 2018.

Sara Beery, Dan Morris, and Siyu Yang. Efficient pipeline for camera trap image review. *arXiv preprint arXiv:1907.06772*, 2019.

Robert Geirhos, Jörn-Henrik Jacobsen, Claudio Michaelis, Richard Zemel, Wieland Brendel, Matthias Bethge, and Felix A. Wichmann. Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2(11): 665–673, 2020.

Agrim Gupta, Piotr Dollár, and Ross Girshick. LVIS: A dataset for large vocabulary instance segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5356–5364, 2019.

Glenn Jocher, Ayush Chaurasia, and Jing Qiu. Ultralytics YOLOv8. `https://github.com/ultralytics/ultralytics`, 2023.

Pang Wei Koh, Shiori Sagawa, Henrik Marklund, et al. WILDS: A benchmark of in-the-wild distribution shifts. In *International Conference on Machine Learning (ICML)*, pages 5637–5664, 2021.

Tsung-Yi Lin, Michael Maire, Serge Belongie, et al. Microsoft COCO: Common objects in context. In *European Conference on Computer Vision (ECCV)*, pages 740–755, 2014.

Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 2980–2988, 2017.

Mohammad Sadegh Norouzzadeh, Anh Nguyen, Margaret Kosmala, Alexandra Swanson, Meredith S. Palmer, Craig Packer, and Jeff Clune. Automatically identifying, counting, and describing wild animals in camera-trap images with deep learning. *Proceedings of the National Academy of Sciences*, 115(25):E5716–E5725, 2018.

Timothy G. O'Brien, Margaret F. Kinnaird, and Hariyo T. Wibisono. Crouching tigers, hidden prey: Sumatran tiger and prey populations in a tropical forest landscape. *Animal Conservation*, 6(2):131–139, 2003.

Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 779–788, 2016.

Stefan Schneider, Graham W. Taylor, and Stefan Kremer. Deep learning object detection methods for ecological camera trap data. In *Conference on Computer and Robot Vision (CRV)*, pages 321–328, 2018.

Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 618–626, 2017.

Michael A. Tabak, Mohammad S. Norouzzadeh, David W. Wolfson, et al. Machine learning to classify animal species in camera trap images: Applications in ecology. *Methods in Ecology and Evolution*, 10(4):585–590, 2019.

Alexandru Telea. An image inpainting technique based on the fast marching method. *Journal of Graphics Tools*, 9(1):23–34, 2004.

Chien-Yao Wang, I-Hau Yeh, and Hong-Yuan Mark Liao. YOLOv9: Learning what you want to learn using programmable gradient information. *arXiv preprint arXiv:2402.13616*, 2024.